Декомпозиция проекта:

1 Введение

1.1 Описание проекта

В рамках данного проекта необходимо приоритизировать полученные гипотезы, а также изучить и проанализировать результаты A/B теста.

1.2 Задачи проекта

1)Приоритизировать полученные гипотезы применив методы ICE и RICE и сравнить результаты.

2)Произвести анализ результата A/B теста.

1.3 Описание данных

Данные для первой части:

Файл /datasets/hypothesis.csv

- Hypothesis — краткое описание гипотезы;
- Reach — охват пользователей по 10-балльной шкале;
- Impact — влияние на пользователей по 10-балльной шкале;
- Confidence — уверенность в гипотезе по 10-балльной шкале;
- Efforts — затраты ресурсов на проверку гипотезы по 10-балльной шкале. Чем больше значение * Efforts, тем дороже проверка гипотезы.

Данные для второй части:

Файл /datasets/orders.csv

- transactionId — идентификатор заказа;
- visitorId — идентификатор пользователя, совершившего заказ;
- date — дата, когда был совершён заказ;
- revenue — выручка заказа;
- group — группа A/B-теста, в которую попал заказ.

Файл /datasets/visitors.csv. Скачать датасет

- date — дата;
- group — группа A/B-теста;
- visitors — количество пользователей в указанную дату в указанной группе A/B-теста

2 Загрузка и изучение данных

2.1 Загрузка данных

In [1]:
```
import pandas as pd
import numpy as np
from datetime import datetime, timedelta
from matplotlib import pyplot as plt
import scipy.stats as stats
```

In [2]:
```
hypothesis, orders, visitors = (
    pd.read_csv('https://code.s3.yandex.net/datasets/hypothesis.csv'),
    pd.read_csv('https://code.s3.yandex.net/datasets/orders.csv'),
    pd.read_csv('https://code.s3.yandex.net/datasets/visitors.csv')
)
```

2.2 Изучение данных

In [3]:
```
hypothesis
```

Out[3]:

	Hypothesis	Reach	Impact	Confidence	Efforts
0	Добавить два новых канала привлечения трафика,...	3	10	8	6
1	Запустить собственную службу доставки, что сок...	2	5	4	10
2	Добавить блоки рекомендаций товаров на сайт ин...	8	3	7	3
3	Изменить структура категорий, что увеличит кон...	8	3	3	8
4	Изменить цвет фона главной страницы, чтобы уве...	3	1	1	1
5	Добавить страницу отзывов клиентов о магазине,...	3	2	2	3
6	Показать на главной странице баннеры с актуаль...	5	3	8	3
7	Добавить форму подписки на все основные страни...	10	7	8	5
8	Запустить акцию, дающую скидку на товар в день...	1	9	9	5

Представлено 9 гипотиз

In [4]:
```
hypothesis.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9 entries, 0 to 8
Data columns (total 5 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   Hypothesis  9 non-null      object
 1   Reach       9 non-null      int64
 2   Impact      9 non-null      int64
 3   Confidence  9 non-null      int64
 4   Efforts     9 non-null      int64
dtypes: int64(4), object(1)
memory usage: 488.0+ bytes
```

Все данные приведены к корректному типу

In [5]:
```
orders.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1197 entries, 0 to 1196
Data columns (total 5 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   transactionId  1197 non-null   int64
 1   visitorId      1197 non-null   int64
 2   date           1197 non-null   object
 3   revenue        1197 non-null   int64
 4   group          1197 non-null   object
dtypes: int64(3), object(2)
memory usage: 46.9+ KB
```

Необходимо привести данные колонки date к типу datetime

In [6]:
```
visitors.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 62 entries, 0 to 61
Data columns (total 3 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   date      62 non-null     object
 1   group     62 non-null     object
 2   visitors  62 non-null     int64
dtypes: int64(1), object(2)
memory usage: 1.6+ KB
```

Необходимо привести данные колонки date к типу datetime

2.3 Вывод

В hypothesis представлено 9 гипотез, в orders и visitors необходимо поправить тип данных и привести название столбцов к стандартному, легко читаемому виду.

3 Предобработка данных

3.1 Приведение названия столбцов к стандартному виду

In [7]:
```
orders.rename(columns = {'transactionId' : 'transaction_id', 'visitorId' : 'visitor_id'}, inplace = True)
```

3.2 Преобразование данных к необходимому для анализа типу

In [8]:
```
orders['date'] = pd.to_datetime(orders['date'])
visitors['date'] = pd.to_datetime(visitors['date'])
```

3.3 Проверка данных на явные и неявные дубликаты

In [9]:
```
for i in (visitors, orders):
    print(i.duplicated().any())
```

```
False
False
```

Дубликатов нет

3.4 Проверка данных на пропуски и аномалии

In [10]:
```
print(orders.isna().sum())
print(visitors.isna().sum())
```

```
transaction_id    0
visitor_id        0
date              0
revenue           0
group             0
dtype: int64
date        0
group       0
visitors    0
dtype: int64
```

Пропусков нет

Проверим таблицу orders на соблюдение условий проведения a/b тестирования:

если есть пользователи, которые попали и в группу А и в группу В удалим их и посмотрим сколько данных мы потеряем.Созданим дополнительный пареметр ignore, в случае если захотим провести анализ данных без изменения, передадим ему значение True

In [11]:
```
orders
```

Out[11]:

	transaction_id	visitor_id	date	revenue	group
0	3667963787	3312258926	2019-08-15	1650	B
1	2804400009	3642806036	2019-08-15	730	B
2	2961555356	4069496402	2019-08-15	400	A
3	3797467345	1196621759	2019-08-15	9759	B
4	2282983706	2322279887	2019-08-15	2308	B
...	...	...	...	...	...
1192	2662137336	3733762160	2019-08-14	6490	B
1193	2203539145	370388673	2019-08-14	3190	A
1194	1807773912	573423106	2019-08-14	10550	A
1195	1947021204	1614305549	2019-08-14	100	A
1196	3936777065	2108080724	2019-08-15	202740	B

1197 rows × 5 columns

In [12]:
```
len(
    np.intersect1d(orders.query('group == "A"')['visitor_id']
    , orders.query('group == "B"')['visitor_id']
    , assume_unique = False)
)
```

Out[12]: 58

58 пользователей находятся и в группе А и в группе В

In [13]:
```
ignore = False
if not ignore:
    a = orders[orders['group'] == 'A']['visitor_id'].drop_duplicates().reset_index()
    b = orders[orders['group'] == 'B']['visitor_id'].drop_duplicates().reset_index()
    c = a.loc[a['visitor_id'].isin(b['visitor_id'])]
    orders = orders.loc[~(orders['visitor_id'].isin(c['visitor_id']))]
```

In [14]:
```
orders
```

Out[14]:

	transaction_id	visitor_id	date	revenue	group
0	3667963787	3312258926	2019-08-15	1650	B
1	2804400009	3642806036	2019-08-15	730	B
3	3797467345	1196621759	2019-08-15	9759	B
4	2282983706	2322279887	2019-08-15	2308	B
5	182168103	935554773	2019-08-15	2210	B
...	...	...	...	...	...
1191	3592955527	608641596	2019-08-14	16490	B
1192	2662137336	3733762160	2019-08-14	6490	B
1193	2203539145	370388673	2019-08-14	3190	A
1194	1807773912	573423106	2019-08-14	10550	A
1196	3936777065	2108080724	2019-08-15	202740	B

1016 rows × 5 columns

При обработке было удалено 15 процентов данных, однако это необходимая мера для проведения точного A/B теста, так же стоит заметить, что нет возможности удалить данных пользователей из visitors

In [15]:
```
visitors
```

Out[15]:

	date	group	visitors
0	2019-08-01	A	719
1	2019-08-02	A	619
2	2019-08-03	A	507
3	2019-08-04	A	717
4	2019-08-05	A	756
...	...	...	...
57	2019-08-27	B	720
58	2019-08-28	B	654
59	2019-08-29	B	531
60	2019-08-30	B	490
61	2019-08-31	B	718

62 rows × 3 columns

In [16]:
```
visitors.groupby('group', as_index = False).agg({'visitors': 'sum'})
```

Out[16]:

	group	visitors
0	A	18736
1	B	18916

Количество пользователей за период исследования примерно равно(разница менее 1 процента), не идеально, но удовлетворяет условиям A/B теста

3.6 Вывод

На данном этапе данные были приведены к необходимому типу для дальнейшего анализа, проверены на наличие дубликатов и пропусков, а так же из visitors исключины пользователи относившиеся к двум группам тестирования

4 Исследовательский анализ данных

4.1 ICE и RICE

Изучим гипотезы подробнее

In [17]:
```
pd.options.display.max_colwidth = 150
hypothesis
```

Out[17]:

	Hypothesis	Reach	Impact	Confidence	Efforts
0	Добавить два новых канала привлечения трафика, что позволит привлекать на 30% больше пользователей	3	10	8	6
1	Запустить собственную службу доставки, что сократит срок доставки заказов	2	5	4	10
2	Добавить блоки рекомендаций товаров на сайт интернет магазина, чтобы повысить конверсию и средний чек заказа	8	3	7	3
3	Изменить структура категорий, что увеличит конверсию, т.к. пользователи быстрее найдут нужный товар	8	3	3	8
4	Изменить цвет фона главной страницы, чтобы увеличить вовлеченность пользователей	3	1	1	1
5	Добавить страницу отзывов клиентов о магазине, что позволит увеличить количество заказов	3	2	2	3
6	Показать на главной странице баннеры с актуальными акциями и распродажами, чтобы увеличить конверсию	5	3	8	3
7	Добавить форму подписки на все основные страницы, чтобы собрать базу клиентов для email-рассылок	10	7	8	5
8	Запустить акцию, дающую скидку на товар в день рождения	1	9	9	5

Рассчитаем ICE для гипотиз и построим график

In [18]:
```
hypothesis['Ice'] = round(hypothesis['Impact'] * hypothesis['Confidence'] / hypothesis['Efforts'])

hypothesis[['Hypothesis', 'Ice']].sort_values('Ice', ascending = False)
```

Out[18]:

	Hypothesis	Ice
8	Запустить акцию, дающую скидку на товар в день рождения	16.0
0	Добавить два новых канала привлечения трафика, что позволит привлекать на 30% больше пользователей	13.0
7	Добавить форму подписки на все основные страницы, чтобы собрать базу клиентов для email-рассылок	11.0
6	Показать на главной странице баннеры с актуальными акциями и распродажами, чтобы увеличить конверсию	8.0
2	Добавить блоки рекомендаций товаров на сайт интернет магазина, чтобы повысить конверсию и средний чек заказа	7.0
1	Запустить собственную службу доставки, что сократит срок доставки заказов	2.0
3	Изменить структура категорий, что увеличит конверсию, т.к. пользователи быстрее найдут нужный товар	1.0
4	Изменить цвет фона главной страницы, чтобы увеличить вовлеченность пользователей	1.0
5	Добавить страницу отзывов клиентов о магазине, что позволит увеличить количество заказов	1.0

In [19]:
```
plt.scatter(hypothesis.index, hypothesis['Ice'])
plt.title('ICE каждой гипотизы');
```

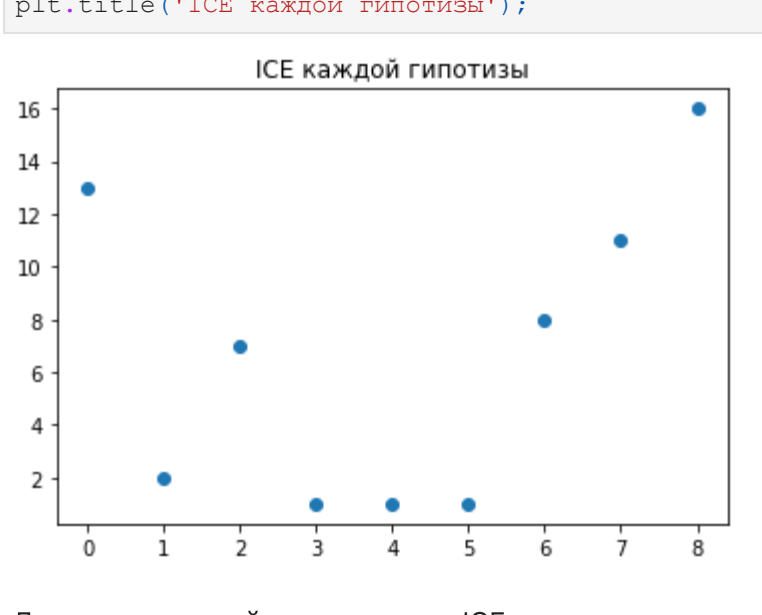

Лучшая гипотезой по параметру ICE - гипотеза с индексом 8(Запустить акцию, дающую скидку на товар в день рождения)

Рассчитаем RICE для гипотез и построим график

In [20]:
```
hypothesis['Rice'] = round(hypothesis['Reach'] * hypothesis['Impact'] * hypothesis['Confidence'] / hypothesis['
hypothesis[['Hypothesis', 'Rice']].sort_values('Rice', ascending = False)
```

Out[20]:

	Hypothesis	Rice
7	Добавить форму подписки на все основные страницы, чтобы собрать базу клиентов для email-рассылок	112.0
2	Добавить блоки рекомендаций товаров на сайт интернет магазина, чтобы повысить конверсию и средний чек заказа	56.0
0	Добавить два новых канала привлечения трафика, что позволит привлекать на 30% больше пользователей	40.0
6	Показать на главной странице баннеры с актуальными акциями и распродажами, чтобы увеличить конверсию	40.0
8	Запустить акцию, дающую скидку на товар в день рождения	16.0
3	Изменить структура категорий, что увеличит конверсию, т.к. пользователи быстрее найдут нужный товар	9.0
1	Запустить собственную службу доставки, что сократит срок доставки заказов	4.0
5	Добавить страницу отзывов клиентов о магазине, что позволит увеличить количество заказов	4.0
4	Изменить цвет фона главной страницы, чтобы увеличить вовлеченность пользователей	3.0

In [21]:
```
plt.scatter(hypothesis.index, hypothesis['Rice'])
plt.title('RICE каждой гипотезы');
```

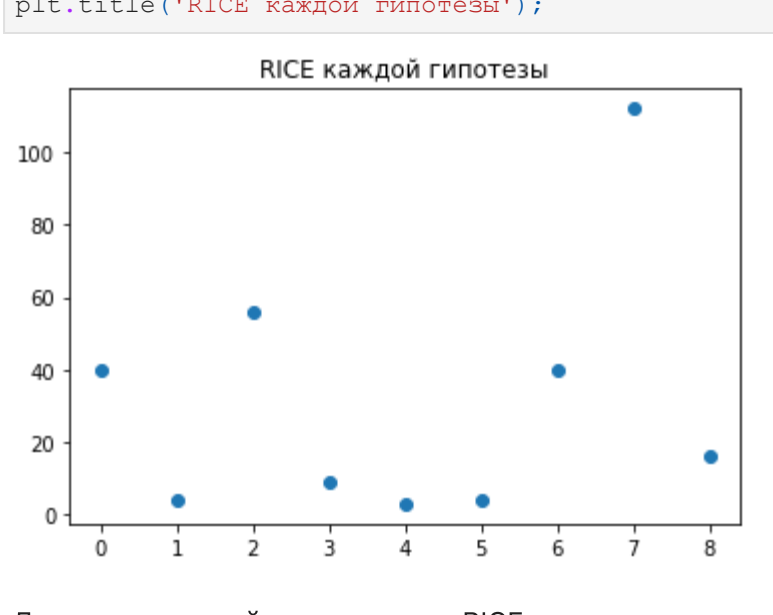

Лучшая гипотезой по параметру RICE - гипотеза с индексом 7(Добавить форму подписки на все основные страницы, чтобы собрать базу клиентов для email-рассылок)

4.1.1 Вывод

При приоритизации гипотез основным показателем был выбран RICE, так как он учитывает охват пользователей. Это видно на примере гипотезы о запуске акции, дающей скидку на товар в день рождения, что показывало лучший результат по показателю ICE, но спустилось на 5 место по RICE. У этой гипотезы был минимальный охват, возможно не все пользователи указывали свои дни рождения. Другая гипотеза о добавлении формы подписки на все основные страницы чтобы собрать базу клиентов для email-рассылок, имеет максимальный охват, а значит затронет всех пользователей, что в совокупности с другими высокими показателями должно дать лучший результат.

Приоритетной гипотезой выбрана гипотеза с индексом 7(Добавить форму подписки на все основные страницы, чтобы собрать базу клиентов для email-рассылок)

4.2 A/B тест

4.2.1 Графики комулятивных показателей

Создадим массив уникальных пар значений дат и групп теста

In [22]:
```
orders
```

Out[22]:

	transaction_id	visitor_id	date	revenue	group
0	3667963787	3312258926	2019-08-15	1650	B
1	2804400009	3642806036	2019-08-15	730	B
3	3797467345	1196621759	2019-08-15	9759	B
4	2282983706	2322279887	2019-08-15	2308	B
5	182168103	935554773	2019-08-15	2210	B
...	...	...	...	...	...
1191	3592955527	608641596	2019-08-14	16490	B
1192	2662137336	3733762160	2019-08-14	6490	B
1193	2203539145	370388673	2019-08-14	3190	A
1194	1807773912	573423106	2019-08-14	10550	A
1196	3936777065	2108080724	2019-08-15	202740	B

1016 rows × 5 columns

In [23]:
```
datesGroups = orders[['date', 'group']].drop_duplicates()
datesGroups
```

Out[23]:

	date	group
0	2019-08-15	B
7	2019-08-15	A
45	2019-08-16	A
47	2019-08-16	B
55	2019-08-01	A
...	...	...
1068	2019-08-12	A
1114	2019-08-13	B
1116	2019-08-13	A
1149	2019-08-14	B
1150	2019-08-14	A

62 rows × 2 columns

Соберём агрегированные кумулятивные по дням, для visitors и orders

In [24]:
```
orders_new = datesGroups.apply(
    lambda x : orders[
    np.logical_and(orders['date'] <= x['date'], orders['group'] == x['group'])
    ].agg(
    {'date': 'max',
     'group': 'max',
      'transaction_id': 'nunique',
     'visitor_id': 'nunique',
     'revenue' : 'sum'
    }
    ), axis =1).sort_values(['date', 'group'])
orders_new
```

Out[24]:

	date	group	transaction_id	visitor_id	revenue
55	2019-08-01	A	23	19	142779
66	2019-08-01	B	17	17	59758
175	2019-08-02	A	42	36	234381
173	2019-08-02	B	40	39	221801
291	2019-08-03	A	66	60	346854
...	...	...	...	...	...
533	2019-08-29	B	510	490	4746610
757	2019-08-30	A	460	437	3311413
690	2019-08-30	B	531	511	4955833
958	2019-08-31	A	468	445	3364656
930	2019-08-31	B	548	528	5068972

62 rows × 5 columns

In [25]:
```
visitors.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 62 entries, 0 to 61
Data columns (total 3 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   date      62 non-null     datetime64[ns]
 1   group     62 non-null     object
 2   visitors  62 non-null     int64
dtypes: datetime64[ns](1), int64(1), object(1)
memory usage: 1.6+ KB
```

In [26]:
```
visitors_new = datesGroups.apply(
    lambda x : visitors[
    np.logical_and(visitors['date'] <= x['date'], visitors['group'] == x['group'])
    ].agg(
    {'date': 'max',
     'group': 'max',
     'visitors' : 'sum'
    }
    ), axis =1).sort_values(['date', 'group'])
visitors_new
```

Out[26]:

	date	group	visitors
55	2019-08-01	A	719
66	2019-08-01	B	713
175	2019-08-02	A	1338
173	2019-08-02	B	1294
291	2019-08-03	A	1845
...	...	...	...
533	2019-08-29	B	17708
757	2019-08-30	A	18037
690	2019-08-30	B	18198
958	2019-08-31	A	18736
930	2019-08-31	B	18916

62 rows × 3 columns

Объединим две таблицы и переименуем столбцы, чтобы лучше ориентироваться в данны. Дополнительно расчитаем конверсию и средний чек по дням

In [27]:
```
df = orders_new.merge(visitors_new, left_on = ['date', 'group'], right_on = ['date', 'group'])
df.columns = [
    'date',
    'group',
    'orders',
    'buyers',
    'revenue',
    'visitors',
]
df['conversion'] = df['orders']/df['visitors']
df['mean'] = df['revenue']/df['orders']
df
```

Out[27]:

	date	group	orders	buyers	revenue	visitors	conversion	mean
0	2019-08-01	A	23	19	142779	719	0.031989	6207.782609
1	2019-08-01	B	17	17	59758	713	0.023843	3515.176471
2	2019-08-02	A	42	36	234381	1338	0.031390	5580.500000
3	2019-08-02	B	40	39	221801	1294	0.030912	5545.025000
4	2019-08-03	A	66	60	346854	1845	0.035772	5255.363636
...	...	...	...	...	...	...	...	...
57	2019-08-29	B	510	490	4746610	17708	0.028801	9307.078431
58	2019-08-30	A	460	437	3311413	18037	0.025503	7198.723913
59	2019-08-30	B	531	511	4955833	18198	0.029179	9333.018832
60	2019-08-31	A	468	445	3364656	18736	0.024979	7189.435897
61	2019-08-31	B	548	528	5068972	18916	0.028970	9249.948905

62 rows × 8 columns

Создадим две таблицы с данными - дата, средний чек, доход и конверсия, разбитыми по группам

In [28]:
```
group_A = df[df['group'] == 'A'][['date','mean','revenue', 'conversion']]
group_B = df[df['group'] == 'B'][['date','mean','revenue', 'conversion']]
```

Строим графики комулятивных показателей

In [29]:
```
plt.figure(figsize=(12,4))
plt.plot(group_A['date'], group_A['revenue'], label = 'A')
plt.plot(group_B['date'], group_B['revenue'], label = 'B')
plt.title('График кумулятивной выручки по группам')
plt.legend();
```

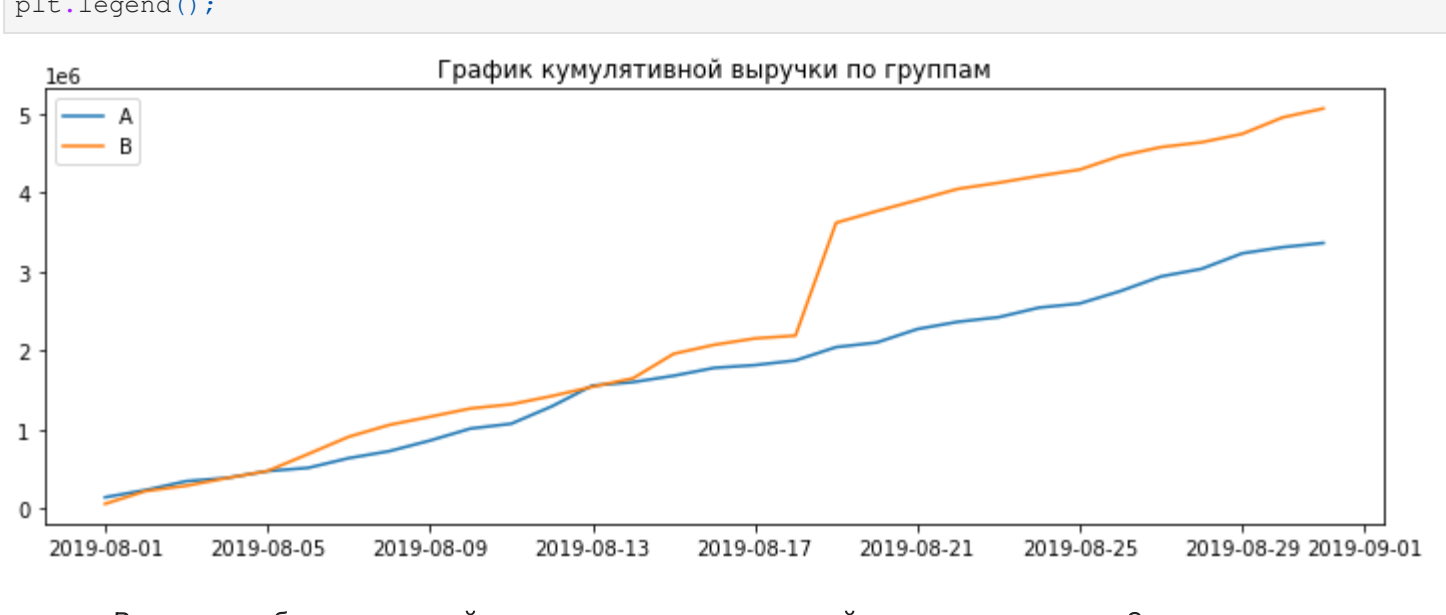

группа В имеет стабильно лучший результат по кумулятивной выручке, а к концу 3 недели преимущество резко увеличивается

In [30]:
```
plt.figure(figsize=(12,4))
plt.plot(group_A['date'], group_A['mean'], label = 'A')
plt.plot(group_B['date'], group_B['mean'], label = 'B')
plt.title('График кумулятивного среднего чека по группам')
plt.legend();
```

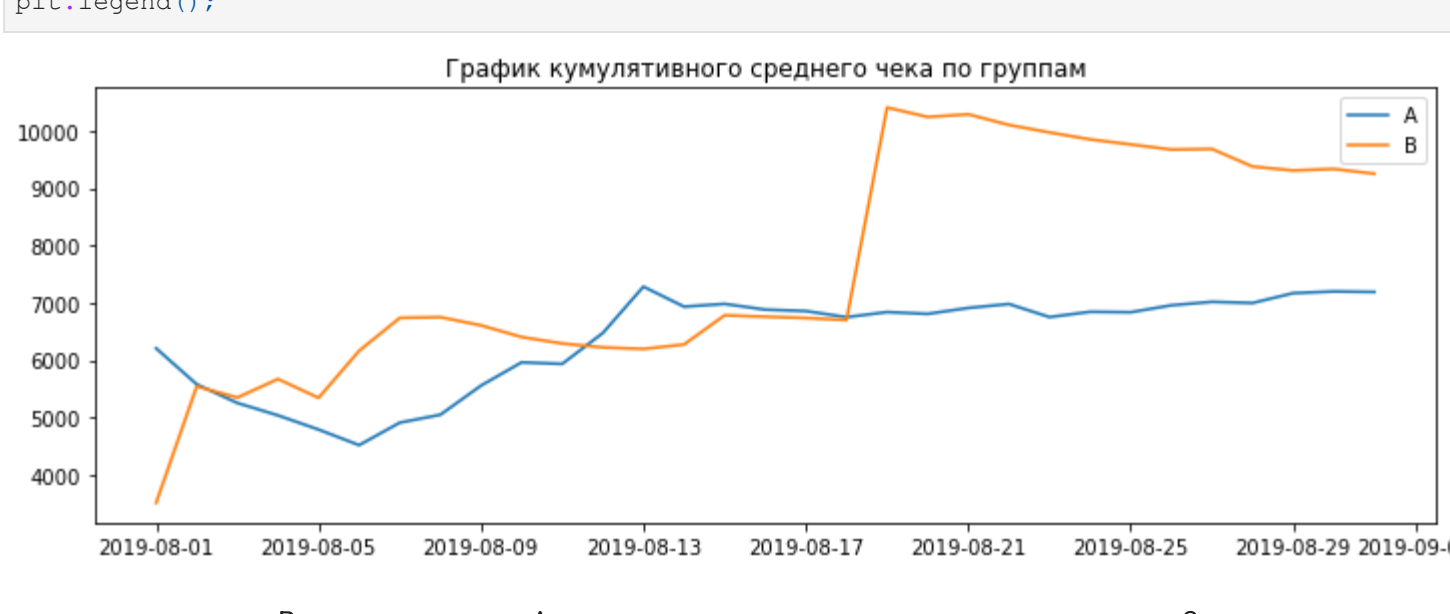

изначально группа В уступает группе А по кумулятивному среднему чеку, но к концу 3 недели значительно опережает

In [31]:
```
merge_groups = group_A.merge(group_B, left_on = 'date', right_on ='date', suffixes=['A', 'B'])
merge_groups
plt.figure(figsize=(12,4))
plt.plot(merge_groups['date'], merge_groups['meanB']/merge_groups['meanA'] - 1)
plt.title('График относительного изменения кумулятивного среднего чека группы B к группе A')
plt.axhline(y=0, color='black', linestyle='--');
```

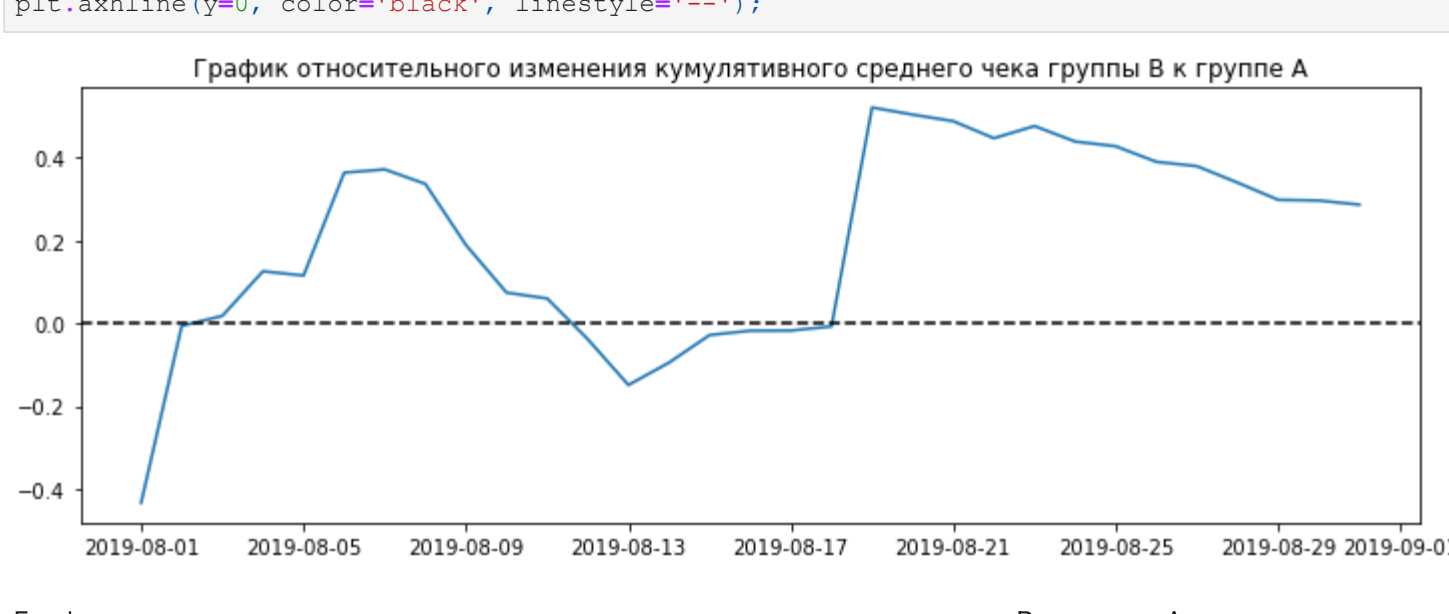

График относительного изменения кумулятивного среднего чека группы B к группе A, так же показывает значительное превосходство группы В над А к концу 3 недели и далее, однако заметны сильные скачки в обе стороны, до этого периода(возможно вызвано выбросами в данных)

In [32]:
```
plt.figure(figsize=(12,4))
plt.plot(group_A['date'], group_A['conversion'], label = 'A')
plt.plot(group_B['date'], group_B['conversion'], label = 'B')
plt.title('График кумулятивной конверсии по группам')
plt.legend();
```

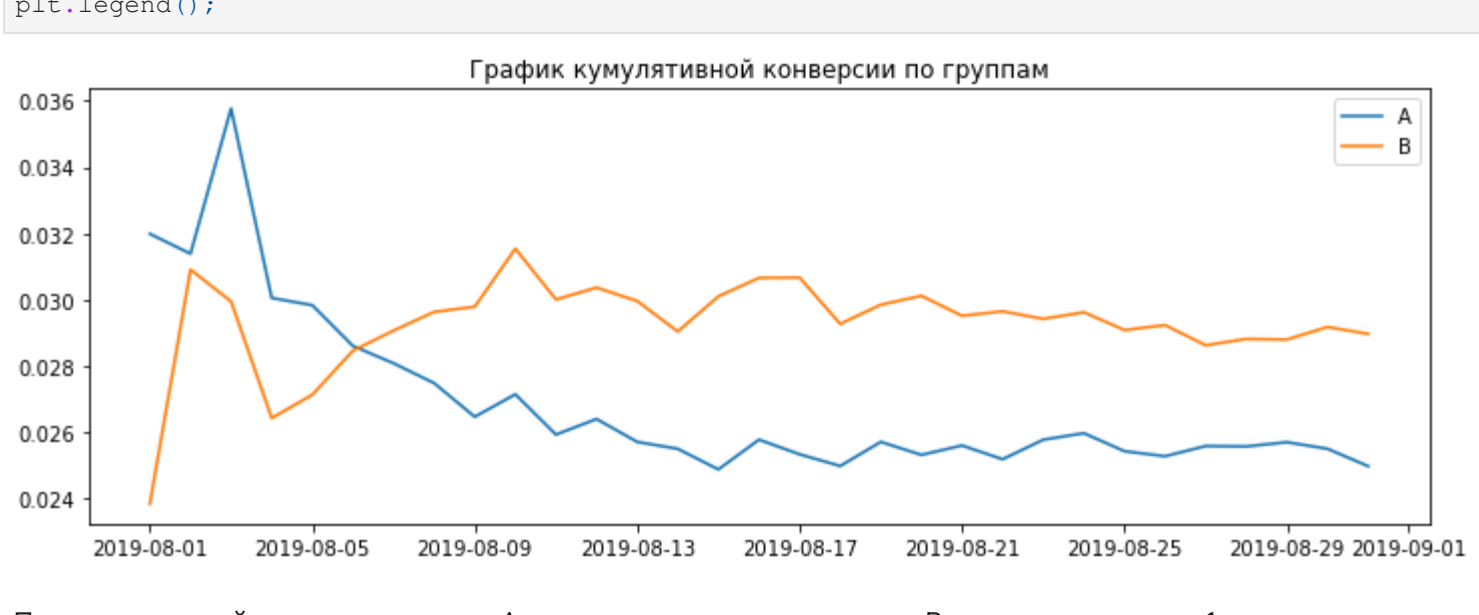

По кумулятивной конверсиигруппа А сначала превосходит группу В, но затем, к концу 1 недели начинает показывает стабильно худший результат, так же стоит сказать что со временем данные стабилизируются и скачки пропадают.

In [33]:
```
plt.figure(figsize=(12,4))
plt.plot(merge_groups['date'], merge_groups['conversionB']/merge_groups['conversionA'] - 1)
plt.title('график относительного изменения кумулятивной конверсии группы B к группе A')
plt.axhline(y=0.1, color='black', linestyle='--')
plt.axhline(y=0, color='black', linestyle='--');
```

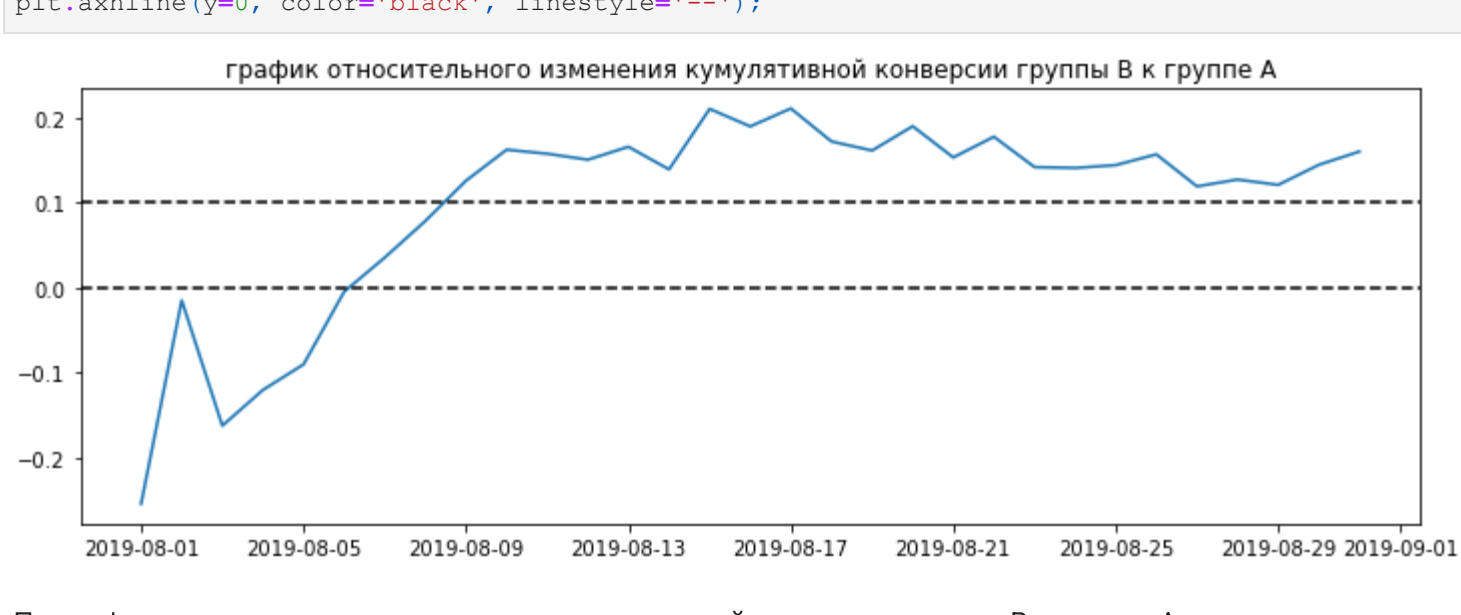

По графику относительного изменения кумулятивной конверсии группы В к группе А можно сказать, что сначала группа В уступает, однако потом к концу первой недели догоняет группу А, и далее стабильно опережает более чем на 10 процентов(временами доходит до 20).

4.2.2 Выбивающиеся значения

In [34]:
```
ordersByUsers = orders.groupby('visitor_id', as_index = False).agg({'transaction_id' : 'nunique'})
ordersByUsers.columns = ['user_id', 'orders']
x_values = pd.Series(range(0,len(ordersByUsers)))
plt.scatter(x_values, ordersByUsers['orders'])
plt.title('Распределение заказов по платящим пользователям');
```



Видно, что только 7 пользователей совершали 3 заказа

In [35]:
```
np.percentile(ordersByUsers['orders'],[95,99])
```

Out[35]:
```
array([1., 2.])
```

Больше двух заказов совершает всего 1 процент пользователей

In [36]:
```
x_values = pd.Series(range(0,len(orders['revenue'])))
plt.scatter(x_values, orders['revenue'])
plt.title('Распределение выручки по платящим пользователям');
```

In [37]:
```
x_values = pd.Series(range(0,len(orders['revenue'])))
plt.scatter(x_values, orders['revenue'])
plt.ylim(0,200000)
plt.title('Распределение выручки по платящим пользователям');
```

Неоднородность проявляется начиная с 25000

In [38]:
```
np.percentile(orders['revenue'],[95,99])
```

Out[38]:
```
array([26785., 53904.])
```

4.2.3 Формулировка нулевых и альтернативных гипотиз

Сформулируем гипотезы, где H0 - нулевая гипотеза, H1 - альтернативная гипотеза

1) H0: конверсии между группами по «сырым» данным равны; H1: конверсии между группами по «сырым» данным

различны;

2) H0: конверсии между группами по «отфильтрованым» данным равны; H1: конверсии между группами по «отфильтрованым» различны;

3) H0: средние чеки заказов между группами по «сырым» данным равны; H1 средние чеки заказов между группами по «сырым» различны;

4) H0: средние чеки заказов между группами по «отфильтрованным» данным равны; H1: средние чеки заказов между группами по «отфильтрованным» не равны;

4.2.4 Проверка статистических гипотез

Напишем функцию для распределения количества заказов по посетителям, которые распределены по группам. Тем кто ничего не заказал присвоим ноль и присоединим их списком пользователей, сделавших заказ, дополнительно добавим фильтр для выбивающихся значений.

In [39]:
```
def con(i,mx = 0, filt = False):
    ordersByUsers = orders.loc[orders['group'] == i].groupby('visitor_id', as_index = False).agg({'transaction_
    ordersByUsers.columns = ['user_id', 'orders']
    count = 0
    if filt:
        count = ordersByUsers[ordersByUsers['orders'] > mx]['orders'].count()
        ordersByUsers = ordersByUsers[ordersByUsers['orders'] <= mx]
    a = pd.Series(0, index = np.arange(visitors[visitors['group'] == i]['visitors'].sum() - len(ordersByUsers['
    sampleA = pd.concat((ordersByUsers['orders'], a), axis = 0)
    return sampleA, count
```

Проверим гипотезу 1.Применим функцию и проверим, если ли различия в распределении количества заказов между группами с помощью критерия Манна-Уитни(для данных с большими выбросами), а также найдем отношение конверсий данных групп.

In [40]:
```
sampleA, count = con('A')
sampleB, count = con('B')
print('p-value',"{0:.3f}".format(stats.mannwhitneyu(sampleA, sampleB)[1]))
print('conv',"{0:.3f}".format(sampleB.mean() / sampleA.mean() - 1))
```

```
p-value 0.011
conv 0.160
```

Для неочищенных данных, разница статистически значима, p-values < 0.05(отвергаем нулевую гипотезу), конверсия группы B больше конверсии группы A на 16 процентов

Проверим гипотезу 2 для очищенных данных.

In [41]:
```
np.percentile(ordersByUsers['orders'],[95,99])
```

Out[41]:
```
array([1., 2.])
```

In [42]:
```
sampleAfilt, countA = con('A', mx = int(np.percentile(ordersByUsers['orders'],[99])), filt = True)
sampleBfilt, countB = con('B', mx = int(np.percentile(ordersByUsers['orders'],[99])), filt = True)
print('количество удаленных пользователей', countA+ countB)
print('p-value',"{0:.3f}".format(stats.mannwhitneyu(sampleAfilt, sampleBfilt)[1]))
print('conv',"{0:.3f}".format(sampleBfilt.mean() / sampleAfilt.mean() - 1))
```

```
количество удаленных пользователей 7
p-value 0.008
conv 0.185
```

После очистки данных статистическая значимость стала еще больше, p-values < 0.01, конверсия группы B больше конверсии группы A на 18 процентов(отвергаем нулевую гипотезу о равенстве конверсий)

Проверим гипотезу 3 для очищенных данных.

Напишем фунцию для разбивки заказов по группам, добавив фильт выручки с каждого заказа

In [43]:
```
def rev(i = 0):
    count = 0
    o = orders
    if i != 0:
        count = orders[orders['revenue'] > i]['revenue'].count()
        o = orders[orders['revenue'] <= i]
    stat = round(stats.mannwhitneyu(o[o['group']=='A']['revenue'], o[o['group']=='B']['revenue'])[1],3)
    mean = round(o[o['group']=='B']['revenue'].mean()/o[o['group']=='A']['revenue'].mean()-1,3)
    return count, stat, mean
```

Применим функцию для определения статистической значимости различий в среднем чеке

In [44]:
```
count, stat, mean = rev(i = 0)
print('p-value', stat)
print('mean', mean)
```

```
p-value 0.829
mean 0.287
```

По неочищенным данным средний чек группы B превосходит группу A на 29 процентов, но разница между этими двумя группами статистически не значима, p-value намного больше 0.05(невозможно опровергнуть гипотезу о равенстве средних чеков в группах)

Проверим 4 гипотезу

In [45]:
```
count, stat, mean = rev(i = int(np.percentile(orders['revenue'],[99])))
print('Число удаленных из анализа пользователей',count)
print('p-value',stat)
print('mean',mean)
```

```
Число удаленных из анализа пользователей 9
p-value 0.901
mean -0.032
```

По очищенным данным средний чек группы B уже уступает группе A на 3 процента, но разница между этими двумя группами все также статистически не значима, p-value намного больше 0.05(невозможно опровергнуть гипотезу о равенстве средних чеков в группах)

4.2.5 Вывод

Различие общей конверсий между группами A и B статистически значимо(в обоих случаях), фиксируем победу группы B по этому показателю(превосходит группу A более чем на 15 процентов)

Различия в среднем чеке заказа между группами A и B статистически не значимы, нельзя сказать что группы отличны по этому показателю.

График различия конверсии между группами по времени сообщает, что результат группы B лучше группы A(к концу 3 недели группа B стабильно опережает группу A более чем на 10 процентов).

5 Рекомендации

1) Признать гипотезу о добавлении формы подписки на все основные страницы, для того чтобы собрать базу клиентов для email-рассылок - приоритетной

2) Остановить A/B тест, зафиксировать победу группы B по показателю конверсии.

3) Дальнейшее наблюдение за средним чеком признать нецелесообразным. Различия в этом показатели абсолютно не являются статистически значимыми , учитывая время проведения теста и количество собранных данных, явных изменений уже не будет.

4) Остановить A/B тест